
Eine Analyse mit dem V-Dem Datensatz zur Identifikation von Faktoren der politischen Instabilität

Adapt the headline in the cell above!

Present a short summary of the pitch! (Add up to 5 bullet points in the cell below)

- Politische Instabilität stellt ein erhebliches Risiko für Länder und die globale Sicherheit dar. Eine frühzeitige Erkennung ist wichtig
- Das Ziel des Projektes ist die Entdeckung länderspezifischer Stereotypen im Hinblick auf ihre politische Stabilität durch eine explorative Datenanalyse
- Regierungen und internationale Organisationen können dadurch gezielter präventive Maßnahmen in Risikoländern ergreifen, weil sie die Faktoren, an denen etwas geändert werden muss, kennen
- Der V-Dem-Datensatz bietet zahlreiche Daten zu politischer Instabilität, Demokratiequalität, Wirtschaft, Bildung und sozialen Indikatoren auf Intervallskalenniveau, die das Clustern und Erkennen von Ländergruppen ermöglichen

Imports and Settings

Use the following code cell to organize all imports and global settings. Do not remove the pandas option. (Commented code, in the next cell)

```
In [59]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
In [60]: # make pandas display ALL columns of a dataframe
pd.options.display.max_columns = None
```

Task 1 -- The Data

Present the origin of the dataset, including e.g. * the source where you got it from (link to the repository), * the author(s), * the license, * the purpose for which it was collected! (Add bullet points in the cell below)

Herkunft des Datensatzes: V-Dem Institut (Varieties of Democracy)

- **Quelle:** [V-Dem Project – Official Website](#)
- **Autoren:** Das V-Dem-Projekt wird geleitet von der V-Dem-Institution unter der Koordination von Staffan I. Lindberg (University of Gothenburg) und einem internationalen Team von Politikwissenschaftler:innen.
- **Lizenz:** Der Datensatz ist unter der [Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License \(CC BY-NC-ND 4.0\)](#) veröffentlicht. Quelle: <https://github.com/vdemoinstitute/vdemdata/releases>
- **Zweck der Datenerhebung:**
Der Datensatz wird jährlich erhoben, um detaillierte und vergleichbare Informationen über Demokratie, politische Institutionen und Menschenrechte in nahezu allen Ländern der Welt über einen langen historischen Zeitraum zu ermöglichen. Er richtet sich insbesondere an Forscher:innen, politische Analyst:innen und Institutionen zur Bewertung demokratischer Entwicklungen weltweit.

The Raw Data

Load the data and present a couple of samples. Call the dataset variable `__raw_data__`. (Commented code, add cells below)

```
In [61]: raw_data = pd.read_csv("data\V-Dem-CY-Full+Others-v15.csv")
```

```
C:\Users\Dell\AppData\Local\Temp\ipykernel_2180\3939445217.py:1: DtypeWarning: Columns (364,365,366,399,804,836,837,924,1240,1257,1486,3094,3168,3169,3341,3342,3344,3345,3347,3350,3352) have mixed types. Specify dtype option on import or set low_memory=False.  
raw_data = pd.read_csv("data\V-Dem-CY-Full+Others-v15.csv")
```

```
In [62]: # Überblick über Struktur und Spalten  
print(raw_data.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27913 entries, 0 to 27912
Columns: 4607 entries, country_name to e_pt_coup_attempts
dtypes: float64(4560), int64(18), object(29)
memory usage: 981.1+ MB
None
```

```
In [63]: # gibt 5 Zufällige Spalten aus
raw_data.sample(5)
```

Out[63]:

	country_name	country_text_id	country_id	year	historical_date	project	historical	hi
2008	Egypt	EGY	13	1904	1904-12-31	2	1	C Empir in
755	Switzerland	CHE	6	1956	1956-12-31	0	1	Confec
23783	New Zealand	NZL	185	1888	1888-12-31	1	1	New i
17689	Guinea-Bissau	GNB	119	1949	1949-12-31	0	0	Cc Port
26669	Bavaria	BVR	350	1861	1861-12-31	1	1	King

```
In [64]: # Ich habe direkt zum Anfang eine Auswahl von Spalten getroffen von denen ich denke
# Da der Datensatz über 4000 Spalten besitzt, war dies nötig. Für die Aufgaben wäre
# Als Kommentar markierte Variablen enthielten zu viele NaNs, weshalb ich mich nach
```

```
relevante_spalten = [
    "country_name",    # Land
    "year",            # Jahr
    "e_wbgi_pve",      # politische Stabilität
    "v2x_libdem",      # Liberale Demokratie (Index)
    "v2x_polyarchy",   # Wahlen (Index)
    "v2x_freexp_altinf", # Meinungs- und Informationsfreiheit (Index)
    "v2xcl_ro1",       # Rechtsstaatlichkeit (Index)
    "v2xcl_acjst",     # Zugang zur Justiz
    "v2x_rule",        # Rule of Law (Index)
    "v2x_pubcorr",     # Öffentliche Korruption
    "v2x_corr",        # politische Korruption
    "v2x_execorr",     # Korruption der Exekutive
    # "e_cow_exports",  # Exporte
    # "e_cow_imports",  # Importe
    # "e_gdp",          # BIP
    # "e_miinflat",     # Inflation
    "e_miferrat",      # Fertilitätsrate
    "e_pelifeex",      # Lebenserwartung
    # "e_civil_war",    # Bürgerkrieg
    "v2cacamps_mean",  # politische Polarisierung
    "v2caviol_mean",   # politische Gewalt
    "v2caassemb_mean", # Versammlungsfreiheit
    "v2cagenmob_mean", # Massenmobilisierung
    "v2caautmob_mean", # Autokratische Bewegungen
    "v2cademmob_mean", # Demokratische Bewegungen
    "v2castate_mean",  # Beteiligung an staatlich organisierten Gruppen
    "v2canonpol_mean", # Beteiligung an unabhängigen nicht-politischen Gruppen
    "v2cafres_mean"    # Freiheit von Forschung und Lehre
]

relevante_spalten = raw_data[relevante_spalten]
```

```
In [65]: # Daten von 2019 bis 2024 filtern
letzten_fünf_jahre = relevante_spalten[
    relevante_spalten["year"].between(2019, 2024)
]

letzten_fünf_jahre.sample(5)
```

```
Out[65]:
```

	country_name	year	e_wbgi_pve	v2x_libdem	v2x_polyarchy	v2x_freexp_altinf	v2xcl_ro1
25196	Saudi Arabia	2021	-0.591	0.045	0.015	0.088	0.178
21612	Equatorial Guinea	2023	NaN	0.053	0.184	0.170	0.213
3741	Bangladesh	2022	-1.092	0.095	0.263	0.379	0.353
6943	Nigeria	2019	-1.933	0.364	0.525	0.871	0.617
6833	Lebanon	2020	-1.621	0.277	0.440	0.724	0.594

Explain the dataset with all its features. * The features should be described in the following table. The range is the set of possible values that a feature can take, e.g. "red, green, blue", " $\mathbb{R}$ ", " $1,2,\dots,12$ ". * You may describe each feature individually or groups of features, if many features are similar (whatever is easier to explain.) (Fill in the table, add bullet points in the next cell)

- Viele Variablen wurden ursprünglich z.B. durch Expertenmeinungen ordinalskaliert erhoben. Anschließend wurden diese Daten in Intervallskalen überführt (Oft auch durch die Bildung von Mittelwerten). Der Datensatz enthält daher Zusätze wie `_ord` oder `_mean`, die verschiedene Skalenniveaus abdecken. Für meine Zwecke werde ich immer Daten nutzen, die auf Intervallskalenniveau vorhanden sind. Neben Daten die auf dem Intervallskalenniveau (meist 0-4) erhoben wurden, gibt es auch indexvariablen, die sich aus verschiedenen Variablen zusammensetzen. Diese haben eine Range von 0-1.

Feature	Wertebereich	Erklärung
country_name	Länder (Strings)	Name des Landes
year	1789 – 2024	Jahr der Messung
e_wbgi_pve	$\mathbb{R}$ (ca. -4 bis 2)	Indikator für politische Stabilität (World Bank Governance Indicator)
v2x_libdem	[0, 1]	Index für liberale Demokratie
v2x_polyarchy	[0, 1]	Index für wahlbasierte Demokratie (Polyarchie)
v2x_freexp_altinf	[0, 1]	Grad der Meinungs- und Informationsfreiheit
v2xcl_rol	[0, 1]	Rechtsstaatlichkeit (Rule of Law)
e_cow_exports	$\mathbb{R}^+$ (%)	Exportquote am BIP
e_cow_imports	$\mathbb{R}^+$ (%)	Importquote am BIP
e_gdp	$\mathbb{R}^+$	Bruttoinlandsprodukt pro Kopf (meist in USD, ggf. logarithmiert)
e_miinflat	$\mathbb{R}$	Jährliche Inflationsrate
e_miferrat	$\mathbb{R}^+$	Fertilitätsrate (Kinder pro Frau)
e_pelifeex	$\mathbb{R}^+$	Lebenserwartung bei Geburt (in Jahren)
e_civil_war	{0, 1}	Bürgerkrieg im Jahr vorhanden (1 = ja)
v2cacamps_mean	[0, 4]	Politische Polarisierung
v2caviol_mean	[0, 4]	Politische Gewalt (Experteneinschätzung)
v2caassemb_mean	[0, 4]	Versammlungsfreiheit (Einschätzung)
v2cagemob_mean	[0, 4]	Mobilisierung durch Protestbewegungen
v2caautmob_mean	[0, 4]	Autokratische soziale Bewegungen
v2cademmob_mean	[0, 4]	Demokratische soziale Bewegungen
v2castate_mean	[0, 4]	Fähigkeit des Staates, Autorität auszuüben
v2canonpol_mean	[0, 4]	Aktivität nichtpolitischer Organisationen
v2cafres_mean	[0, 4]	Ausmaß staatlicher Repression

Explain why the dataset is suitable for the pitched task! (Add up 3 bullet points in the cell below)

- Der V-Dem-Datensatz bietet zahlreiche Daten zu politischer Instabilität, Demokratiequalität, Wirtschaft, Bildung und sozialen Indikatoren auf Intervallskalenniveau, die das Clustern und Erkennen von Ländergruppen ermöglichen.
- Eine Erstellung von Stereotypen durch verschiedene Clusteranalysen bezüglich der Variable der politischen Stabilität (und anderen) ist möglich.
 - Es könnten bezüglich der Variablen Gemeinsamkeiten und Zusammenhänge gefunden werden

Task 2 -- Initial Data Analysis

Initial Data Analysis (IDA): Present relevant quantities about the data. (Commented Code + bullet points, add cells below)

```
In [66]: # Anzahl der Zeilen und Spalten
raw_data.shape
```

```
Out[66]: (27913, 4607)
```

```
In [67]: # Alle Länder zählen
# ISO 3166-1 führt 249 Ländercodes, inklusive abhängiger Gebiete und Sonderverwaltu
# Allgemein sind aber nur 195 Länder anerkannt.
raw_data["country_name"].nunique()
```

```
Out[67]: 202
```

```
In [68]: # Statistische Kennzahlen für numerische Spalten
relevante_spalten.describe()
```

```
Out[68]:
```

	year	e_wbgi_pve	v2x_libdem	v2x_polyarchy	v2x_freexp_altinf	v2xcl_rol	
count	27913.000000	4123.000000	25530.000000	26775.000000	27377.000000	27795.000000	27
mean	1929.594096	-0.172125	0.221204	0.262252	0.419814	0.452601	
std	64.943165	0.970291	0.231332	0.262190	0.310917	0.304654	
min	1789.000000	-3.313000	0.005000	0.006000	0.010000	0.000000	
25%	1881.000000	-0.771000	0.057000	0.055000	0.132000	0.173000	
50%	1940.000000	-0.094000	0.124000	0.167000	0.350000	0.412000	
75%	1985.000000	0.594000	0.296000	0.371000	0.710000	0.721000	
max	2024.000000	1.759000	0.897000	0.923000	0.989000	0.993000	

fehlende Werte

- Die Analyse von fehlenden Werten hinsichtlich relevanter Variablen ist besonders wichtig für mein Projekt. Die Länder lassen sich nur vernünftig Clustern, wenn es genug Daten gibt. Ich muss wissen, welche Häufigkeiten bezüglich einer Variable je Land existieren.
- Ein Weiterer Punkt ist, dass die Erhebung der Variablen unterschiedliche Start und Endzeitpunkte haben kann, sodass sich die Datenabdeckung je nach Zeitraum erheblich verändern kann.
- Ich möchte primär Wissen wie sich die Datenabdeckung der Zielvariable e_wbgi_pve (politische Stabilität) verhält und in welchem Zeitraum und in Welchen Ländern die erklärenden Variablen eine Clusteranalyse zulassen.

```
In [69]: # Überblick über fehlende Werte jeder Spalte
fehlende_werte = relevante_spalten.isnull().sum()
fehlende_werte
```

```
Out[69]: country_name      0
year                    0
e_wbgi_pve             23790
v2x_libdem             2383
v2x_polyarchy          1138
v2x_freexp_altinf      536
v2xcl_rol              118
v2xcl_acjst            209
v2x_rule               388
v2x_pubcorr            544
v2x_corr               893
v2x_execorr            696
e_miferrat             2596
e_pelifeex             2596
v2cacamps_mean         8562
v2caviol_mean          8562
v2caassemb_mean        8562
v2cagenmob_mean        8562
v2caautmob_mean        8562
v2cademmob_mean        8562
v2castate_mean         8562
v2canonpol_mean        8562
v2cafres_mean          12579
dtype: int64
```

```
In [70]: # Datenabdeckung checken
# Für jede Spalte zählen, wie viele Nicht-Null-Werte pro Land vorhanden sind
datenabdeckung = relevante_spalten.groupby("country_name").count()
datenabdeckung
```


Out[70]:

	year	e_wbgi_pve	v2x_libdem	v2x_polyarchy	v2x_freexp_altinf	v2xcl_rol	v2xcl_acj
country_name							
Afghanistan	236	24	236	236	236	236	236
Albania	113	24	111	111	113	113	113
Algeria	125	24	125	125	125	125	125
Angola	125	24	125	125	125	125	125
Argentina	236	24	236	236	236	236	236
...	...	...	...	...	...	...	...
Württemberg	83	0	57	57	83	83	83
Yemen	169	24	169	169	169	169	169
Zambia	114	24	114	114	114	114	114
Zanzibar	169	0	125	125	169	169	169
Zimbabwe	125	24	125	125	125	125	125

202 rows × 22 columns

In [71]:

```
# Datenabdeckung der letzten Jahre
filtered = relevante_spalten[relevante_spalten["year"].between(1996, 2022)]

# Danach Gruppierung und Zählung der Nicht-Null-Werte je Land und Spalte
datenabdeckung1 = filtered.groupby("country_name").count()

# Ergebnis anzeigen
datenabdeckung1.head()
```

Out[71]:

	year	e_wbgi_pve	v2x_libdem	v2x_polyarchy	v2x_freexp_altinf	v2xcl_rol	v2xcl_acj
country_name							
Afghanistan	27	24	27	27	27	27	27
Albania	27	24	27	27	27	27	27
Algeria	27	24	27	27	27	27	27
Angola	27	24	27	27	27	27	27
Argentina	27	24	27	27	27	27	27

Wichtige Erkenntnisse:

- Es gibt keine Informationen bezüglich der politischen Stabilität zu Palestine/Gaza, zu Palestine/ Westbank, zu Hong Kong, zum Kosovo, zum Somaliland und zu Sansibar
- Die allermeisten Länder haben einen Erhebungszeitraum von 1996 bis 2022 --> Es werden nicht mehr Daten wenn man den Zeitraum erweitert. Obwohl der Zeitraum 27 Jahre umfasst, haben die meisten Länder 24 einträge, weshalb die Erhebung scheinbar 3 mal ausgesetzt worden ist. Die Daten zu einigen wenigen Ländern wurden zudem seltener als 24 mal erhoben. Der SüdSudan wurden nur 12 mal erhoben. Timor-Leste 21 mal, Serbia und Montenegro 17 mal.
- In vielen Anderen Variablen erscheint die Datendichte gut zu sein. Jedoch nicht in allen Variablen. So weist die Variable zum Civilwar, die Variable zum Import, die Variable zum Export und die Variable zur Inflation auf ein paar defizite hin. # --> habe ich nachträglich entfernt. Daher tauchen diese hier gar nicht mehr auf.

Task 3 -- Preprocessing

Conduct all steps of Task 3. Call the result "data". (Commented code + bullet points, add cells below)

- Ich möchte direkt wissen wofür die einzelnen Spaltennamen stehen. --> Umbenennen
- Ich möchte einen Datensatz mit einer möglichst hohen Datendichte, der die letzten Jahrzehnte abbildet.
- Das Problem ist, dass einige wenige Länder weniger Daten enthalten als andere. Die Spalten sollten jedoch für jedes Land gleichviele Daten bereitstellen.
- Natürlich könnte man nur Daten aus einem Jahr nehmen und hätte dann einen ausgewogenen Datensatz. Jedoch erwarte ich eine bessere und fundiertere Analyse, wenn auch die Vergangenheit analysiert wird.
- Da kein Land im Jahr 1997, 1999, 2001, 2023 und 2024 angaben bezüglich der Hauptvariable (politische Stabilität) besitzt, möchte ich diese Zeilen löschen.
- Ferner sollen auch Länderzeilen denen kein Wert bezüglich der Spalte der politischen Stabilität zugeordnet ist gelöscht werden.
- Bei Ländern mit weniger Werten habe ich lange überlegt, ob man eine Spline-Interpolation verwenden könnte. Eine Spline-Interpolation würde dafür sorgen, dass möglichst realistische Verläufe zwischen den Zeitreihenwerten erzeugt werden. Wenn aber mehrere aufeinander folgende Werte fehlen, dann funktioniert dies nicht. Weil das immer der Fall war, habe ich mich dazu entschieden diese Länder ebenso rauszulöschen.
- Bezüglich der anderen Variablen kann es ebenso vorkommen, dass es nicht gleichviele Zeilen je Land gibt bzw.. das einige Länder gar nicht vertreten sind, weshalb einige wenige Länder schwächer ins Gewicht fallen könnten. Da dies bei einigen Variablen sehr extrem war, habe ich mich entschieden diese Variablen zu löschen bzw.. gar nicht erst zu laden.

In [72]: *# Umbenennen der Spaltennamen*

```
Test = filtered.rename(columns={
    "country_name": "Land",
    "year": "Jahr",
    "e_wbgi_pve": "politische Stabilität",
    "v2x_libdem": "Liberales Demokratie (Index)",
    "v2x_polyarchy": "Wahlen (Index)",
    "v2x_freexp_altinf": "Meinungs- und Informationsfreiheit (Index)",
    "v2xcl_ro1": "Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)",
    "v2xcl_acjst": "Zugang zur Justiz",
    "v2x_rule": "Rechtsstaatlichkeit(Index)",
    "v2x_pubcorr": "Öffentliche Korruption",
    "v2x_corr": "politische Korruption",
    "v2x_execorr": "Korruption der Exekutive",
    "e_cow_exports": "Exporte",
    "e_cow_imports": "Importe",
    "e_gdp": "BIP",
    "e_miinflat": "Inflation",
    "e_miferrat": "Fertilitätsrate",
    "e_pelifeex": "Lebenserwartung",
    "e_civil_war": "Bürgerkrieg",
    "v2cacamps_mean": "politische Polarisierung",
    "v2caviol_mean": "politische Gewalt",
    "v2caassemb_mean": "Versammlungsfreiheit",
    "v2cagenmob_mean": "Massenmobilisierung",
    "v2caautmob_mean": "Autokratische Bewegungen",
    "v2cademmob_mean": "Demokratische Bewegungen",
    "v2castate_mean": "Beteiligung an staatlich organisierten Gruppen",
    "v2canonpol_mean": "Beteiligung an unabhängigen nicht-politischen Gruppen",
    "v2cafres_mean": "Freiheit von Forschung und Lehre"
})
```

In [73]: *# Löschen der besagten Jahreszeilen*

```
Test_cleaned = Test[~Test["Jahr"].isin([1997, 1999, 2001, 2023, 2024])]
```

In [74]: *# Länderzeilen aufgrund mangelhafter Daten löschen.*

erstellen einer Liste dieser Länder

```
raus = ["Palestine/Gaza", "Palestine/West Bank", "Hong Kong", "Kosovo", "Somaliland", "
```

Entfernen der Zeilen aus dem DF. ~ ist das Zeichen für Negation. Es bleiben also

```
Test = Test_cleaned[~Test_cleaned["Land"].isin(raus)]
```

In [75]: `Data = Test.dropna()`

In [76]: `Data = Test`

- Vorstellen der relevanten Kenngrößen, des veränderten finalen DFs.

In [77]: *# Der DF besitzt 4044 Zeilen und 28 Spalten*

```
Data.shape
```

Out[77]: (4056, 23)

```
In [78]: # Insgesamt 26342 Einträge
Data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 4056 entries, 207 to 26342
Data columns (total 23 columns):
#   Column                                                                 Non-Null Count
Dtype
---  -----
0   Land                                                                 4056 non-null
object
1   Jahr                                                                 4056 non-null
int64
2   politische Stabilität                                             4056 non-null
float64
3   Liberale Demokratie (Index)                                       4053 non-null
float64
4   Wahlen (Index)                                                    4056 non-null
float64
5   Meinungs- und Informationsfreiheit (Index)                       4056 non-null
float64
6   Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)    4056 non-null
float64
7   Zugang zur Justiz                                                 4056 non-null
float64
8   Rechtsstaatlichkeit(Index)                                         4056 non-null
float64
9   öffentliche Korruption                                           4056 non-null
float64
10  politische Korruption                                             4050 non-null
float64
11  Korruption der Exekutive                                           4056 non-null
float64
12  Fertilitätsrate                                                   4056 non-null
float64
13  Lebenserwartung                                                    4056 non-null
float64
14  politische Polarisierung                                           4056 non-null
float64
15  politische Gewalt                                                  4056 non-null
float64
16  Versammlungsfreiheit                                              4056 non-null
float64
17  Massenmobilisierung                                                4056 non-null
float64
18  Autokratische Bewegungen                                           4056 non-null
float64
19  Demokratische Bewegungen                                           4056 non-null
float64
20  Beteiligung an staatlich organisierten Gruppen                   4056 non-null
float64
21  Beteiligung an unabhängigen nicht-politischen Gruppen             4056 non-null
float64
22  Freiheit von Forschung und Lehre                                   4019 non-null
float64
dtypes: float64(21), int64(1), object(1)
memory usage: 760.5+ KB
```

```
In [79]: # Übersicht über deskriptive Statistiken
Data.describe()
```

Out[79]:

	Jahr	politische Stabilität	Liberales Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zu Informationen
count	4056.000000	4056.000000	4053.000000	4056.000000	4056.000000	4056.000000	4056
mean	2010.250000	-0.167449	0.406576	0.520684	0.666696	0.672943	0
std	7.339445	0.970768	0.271479	0.264959	0.287130	0.269890	0
min	1996.000000	-3.313000	0.005000	0.015000	0.012000	0.006000	0
25%	2004.750000	-0.772000	0.150000	0.283000	0.504750	0.492000	0
50%	2010.500000	-0.092500	0.371000	0.525500	0.759000	0.741000	0
75%	2016.250000	0.605000	0.653000	0.772000	0.896000	0.909000	0
max	2022.000000	1.759000	0.897000	0.923000	0.989000	0.993000	0

- Datendichte

```
In [80]: # Entscheidend ist wie viele Länder die gleiche Anzahl an Einträgen je Spalte haben
# Der Code soll folgendes Aussagen: z.B. in Der Spalte Liberale Demokratie (Index)

for spalte in Data.columns: # Schleife die durch alle Columns des Dfs Data iteriert
    print(Data.groupby("Land")[spalte].count().value_counts(), "\n")

    # Zuerst wird nach Land gruppiert. Dann wird auf jede Spalte zugegriffen und
    # value_counts zählt dann, wie oft jede mögliche Anzahl von Werten für die
    # 0 müsste bedeuten, z.B. bei Exporte, dass es zu drei Ländern keine Daten
```

Land
24 169
Name: count, dtype: int64

Jahr
24 169
Name: count, dtype: int64

politische Stabilität
24 169
Name: count, dtype: int64

Liberale Demokratie (Index)
24 168
21 1
Name: count, dtype: int64

Wahlen (Index)
24 169
Name: count, dtype: int64

Meinungs- und Informationsfreiheit (Index)
24 169
Name: count, dtype: int64

Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)
24 169
Name: count, dtype: int64

Zugang zur Justiz
24 169
Name: count, dtype: int64

Rechtsstaatlichkeit(Index)
24 169
Name: count, dtype: int64

öffentliche Korruption
24 169
Name: count, dtype: int64

politische Korruption
24 168
18 1
Name: count, dtype: int64

Korruption der Exekutive
24 169
Name: count, dtype: int64

Fertilitätsrate
24 169
Name: count, dtype: int64

Lebenserwartung
24 169
Name: count, dtype: int64

politische Polarisierung

```
24    169
Name: count, dtype: int64
```

politische Gewalt

```
24    169
Name: count, dtype: int64
```

Versammlungsfreiheit

```
24    169
Name: count, dtype: int64
```

Massenmobilisierung

```
24    169
Name: count, dtype: int64
```

Autokratische Bewegungen

```
24    169
Name: count, dtype: int64
```

Demokratische Bewegungen

```
24    169
Name: count, dtype: int64
```

Beteiligung an staatlich organisierten Gruppen

```
24    169
Name: count, dtype: int64
```

Beteiligung an unabhängigen nicht-politischen Gruppen

```
24    169
Name: count, dtype: int64
```

Freiheit von Forschung und Lehre

```
24    164
20      2
17      1
12      1
14      1
Name: count, dtype: int64
```

```
In [81]: # Überblick über fehlende Werte! --> Export, Import, inflation, BIP und Bürgerkrieg
         fehlende_werte1 = Data.isnull().sum()
         fehlende_werte1
```



```
Out[81]: Land 0
        Jahr 0
        politische Stabilität 0
        Liberale Demokratie (Index) 3
        Wahlen (Index) 0
        Meinungs- und Informationsfreiheit (Index) 0
        Gleichheit vor dem Gesetz und individuelle Freiheiten (Index) 0
        Zugang zur Justiz 0
        Rechtsstaatlichkeit(Index) 0
        öffentliche Korruption 0
        politische Korruption 6
        Korruption der Exekutive 0
        Fertilitätsrate 0
        Lebenserwartung 0
        politische Polarisierung 0
        politische Gewalt 0
        Versammlungsfreiheit 0
        Massenmobilisierung 0
        Autokratische Bewegungen 0
        Demokratische Bewegungen 0
        Beteiligung an staatlich organisierten Gruppen 0
        Beteiligung an unabhängigen nicht-politischen Gruppen 0
        Freiheit von Forschung und Lehre 37
        dtype: int64
```

```
In [82]: Data = Data.dropna()
        # Es ist vertretbar die paar Zeilen zu löschen.
```

Task 4 -- Exploratory Data Analysis

Present 3 highlights from the exploratory data analysis in your draft.

(Commented code + bullet points, add cells below under the respective highlight headlines)

In der Final-Stage sollen nur die Highlights vorgestellt werden.

EDA Highlight 1

Korrelationen zwischen Faktoren und politischer Stabilität

- Ich möchte wissen welche Variablen den stärksten Einfluss bzw. Zusammenhang mit der politischen Stabilität haben. Dazu möchte ich alle Variablen mit der Zielvariable korrelieren lassen. Dadurch kann man später gezielter nach Clustern suchen und weiß welche Variablen relevant sein werden.

```
In [83]: # Liste aller relevanten Variablen --> alle außer "Land" und "Jahr" und politische
# politische Stabilität muss enthalten sein, weil man diese Variable zur Berechnung
relevante_variablen = [
    'Liberaler Demokratie (Index)', 'Wahlen (Index)', 'Meinungs- und Informationsfrei-
    'Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)', 'Zugang zur Justiz',
    'Öffentliche Korruption', 'politische Korruption', 'Korruption der Exekutive',


    # 'Exporte', 'Importe', 'BIP', 'Inflation', 'Bürgerkrieg',
    'Fertilitätsrate', 'Lebenserwartung', 'politische Polarisierung', 'politische
    'Versammlungsfreiheit', 'Massenmobilisierung', 'Autokratische Bewegungen',
    'Demokratische Bewegungen', 'Beteiligung an staatlich organisierten Gruppen',
    'Beteiligung an unabhängigen nicht-politischen Gruppen', 'Freiheit von Forschung und
    "politische Stabilität"
]
```

```
In [84]: # Korrelation jeder Variable mit "politische Stabilität"
Korrelationen = Data[relevante_variablen].corr()['politische Stabilität']
```

```
In [85]: # sortieren
Korrelationen_sorted = Korrelationen.sort_values()
Korrelationen_sorted
```

```
Out[85]: politische Gewalt                -0.789834
politische Korruption                -0.718109
öffentliche Korruption                -0.689218
Korruption der Exekutive              -0.667066
politische Polarisierung              -0.564798
Fertilitätsrate                      -0.532793
Autokratische Bewegungen              -0.468618
Demokratische Bewegungen              -0.411852
Beteiligung an staatlich organisierten Gruppen -0.382840
Massenmobilisierung                  -0.362440
Beteiligung an unabhängigen nicht-politischen Gruppen 0.271101
Meinungs- und Informationsfreiheit (Index) 0.343190
Freiheit von Forschung und Lehre      0.395799
Versammlungsfreiheit                 0.460383
Lebenserwartung                     0.471214
Wahlen (Index)                      0.545407
Liberaler Demokratie (Index)         0.612404
Gleichheit vor dem Gesetz und individuelle Freiheiten (Index) 0.645330
Zugang zur Justiz                    0.649881
Rechtsstaatlichkeit(Index)           0.690315
politische Stabilität                 1.000000
Name: politische Stabilität, dtype: float64
```

```
In [86]: plt.figure(figsize=(10, 5))
sns.barplot(x=Korrelationen_sorted.values, y=Korrelationen_sorted.index)
# y=Korrelationen_sorted.index --> Das sind die Variablennamen, x= Korrelationen_s
#Werte(Korrelationskoeffizienten)
plt.xlabel('Korrelationskoeffizient')
plt.title('Korrelationen mit politischer Stabilität (sortiert)')
plt.show()
```



- **Starker negativer Zusammenhang:** Die Variablen politische Gewalt sowie die verschiedenen Formen von Korruption (politisch, öffentlich, Exekutive) zeigen einen deutlich negativen Zusammenhang mit der politischen Stabilität. Je stärker diese Merkmale ausgeprägt sind, desto niedriger ist in der Regel die politische Stabilität eines Landes. Diese Variablen haben somit einen besonders starken Einfluss auf instabile Länder.
- **Starker positiver Zusammenhang:** Ein klar positiver Zusammenhang besteht bei Variablen wie liberale Demokratie, Rechtsstaatlichkeit, Zugang zur Justiz, Gleichheit vor dem Gesetz sowie individuelle Freiheitsrechte. Hohe Ausprägungen in diesen Bereichen gehen typischerweise mit höherer politischer Stabilität einher und charakterisieren somit politisch stabile Länder.
- **Wirtschaftliche Faktoren** wie BIP, Exporte, Importe oder Inflation zeigen hingegen überraschend geringe Korrelationen mit der politischen Stabilität. Ihr Einfluss scheint im Vergleich zu demokratischen oder gewaltbezogenen Faktoren begrenzt zu sein.
- Ferner legt die Analyse nahe, welche Variablen besonders relevant für Clusteranalysen sein könnten: Nämlich diejenigen mit einer hohen Korrelation.


EDA Highlight 2

Gruppieren nach stark negativen Korrelationsvariablen

- ich möchte alle Länder mit hohen Werten in den Variablen der Korruption und in der Variable politische Gewalt etc.. in eine Gruppe überführen.
- danach möchte ich zur Veranschaulichung eine Verteilung erstellen.
- Abschließend möchte ich wissen welche Länder enthalten sind, und wie häufig.

```
In [87]: # Erstellen der Gruppe anhand ihrer quantile
gewalt_korruppte_länder = Data[
    (Data["politische Gewalt"] > Data["politische Gewalt"].quantile(0.66)) &
    (Data["politische Korruption"] > Data["politische Korruption"].quantile(0.66)) &
    (Data["öffentliche Korruption"] > Data["öffentliche Korruption"].quantile(0.66)) &
    (Data["Korruption der Exekutive"] > Data["Korruption der Exekutive"].quantile(0.66))
]
```

```
In [88]: #Plotten
plt.figure(figsize=(10, 5))
sns.histplot(gewalt_korruppte_länder["politische Stabilität"])
plt.title('Verteilung der politischen Stabilität (korrupt & gewalttätig)')
plt.xlabel('politische Stabilität')
plt.ylabel('Anzahl Länder (Jahre)')
plt.show()
```




- Während der Durschnitt der politischen Stabilität ohne Filterung nach politischer Gewalt und Korruptionsarten noch bei 0 lag, liegt er nun bei -1.38926. Es ist also davon auszugehen, dass die ausgewählten Länder mit hoher politischer Gewalt und ausgeprägten Korruptionsformen deutlich instabiler sind als der globale Durchschnitt, was bestätigt, dass diese Variablen starke Prädiktoren für politische Instabilität darstellen.

EDA Highlight 3

```
In [89]: sns.scatterplot(data=Data, x="Rechtsstaatlichkeit(Index)", y='politische Korruption')

# Titel und Achsenbeschriftung
plt.title('Scatterplot mit Seaborn')
plt.xlabel('Rechtsstaatlichkeit')
plt.ylabel('politische Stabilität')

# Zeige das Diagramm
plt.show()
```



Der Plot zeigt, wie sich die Daten verhalten könnten, wenn alle Features in eine Clusteranalyse mit eingebunden sind. Die Daten weisen gemäß der Korrelation zur politischen Stabilität auf ein zweidimensionales Spektrum zwischen liberal, rechtsstatlich und autoritär korrupt hin.

Task 5 -- Dimensionality Reduction

PCA: Conduct your analyses and transformations according to Task 5. Call the transformed dataset "data_pca". (Commented code + bullet points, add cells below)

```
In [90]: import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from pca import pca
```

- Ich muss die Variable der politischen Stabilität aus dem DF für die PCA entfernen, weil sie nicht Teil der erklärenden Variablen ist.
- Ferner dürfen keine NaN Werte enthalten sein.

```
In [91]: Data_ohne_pS = Data.drop(columns=['politische Stabilität'])
Data_ohne_pS = Data_ohne_pS.dropna()
```

- Land und Jahr kann als index genutzt werden

```
In [92]: pca_vorbereitung = Data_ohne_pS.set_index(['Land', 'Jahr'])
```

- Standardisieren der numerischen Daten

```
In [93]: # alle numerischen Spalten müssen so transformiert werden, dass sie im Mittelwert
scaler = StandardScaler()
data_pca_v = scaler.fit_transform(pca_vorbereitung)

# Es wird ein neuer DF erstellt (aus den skalierten Werten). Aber der Index bleibt
data_pca_v = pd.DataFrame(data_pca_v, index=pca_vorbereitung.index, columns=pca_vo

data_pca_v.round(2)
```

Out[93]:

		Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichk
Land	Jahr						
Mexico	1996	-0.44	-0.06	0.06	-0.32	-0.93	
	1998	-0.12	0.28	0.06	-0.32	-0.93	
	2000	0.27	0.53	0.37	-0.31	-0.93	
	2002	0.32	0.62	0.45	-0.27	-0.93	
	2003	0.34	0.66	0.45	-0.27	-0.93	
...	...	...	...	...	...	...	
Hungary	2018	-0.13	-0.15	-0.31	0.82	0.71	
	2019	-0.17	-0.20	-0.33	0.81	0.71	
	2020	-0.19	-0.21	-0.45	0.75	0.71	
	2021	-0.24	-0.27	-0.51	0.77	0.71	
	2022	-0.27	-0.27	-0.55	0.78	0.65	

4013 rows × 20 columns

- Die Tabelle zeigt die standardisierten Werte der Variablen. Dieser Schritt ist wichtig, weil er sicherstellt, dass alle Variablen denselben Einfluss auf den PCA-Prozess haben. Andernfalls könnte PCA durch Variablen mit größeren Zahlen dominiert werden, was das Ergebnis verzerren würde.

In [94]: `data_pca_v.cov().round(2)`

Out[94]:

	Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichkeit
Liberaler Demokratie (Index)	1.00	0.98	0.85	0.88	0.83	
Wahlen (Index)	0.98	1.00	0.90	0.88	0.79	
Meinungs- und Informationsfreiheit (Index)	0.85	0.90	1.00	0.84	0.72	
Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	0.88	0.88	0.84	1.00	0.92	
Zugang zur Justiz	0.83	0.79	0.72	0.92	1.00	
Rechtsstaatlichkeit (Index)	0.91	0.85	0.71	0.88	0.88	
öffentliche Korruption	-0.81	-0.73	-0.54	-0.75	-0.76	
politische Korruption	-0.79	-0.70	-0.50	-0.72	-0.76	
Korruption der Exekutive	-0.81	-0.72	-0.55	-0.74	-0.76	
Fertilitätsrate	-0.48	-0.43	-0.19	-0.44	-0.44	
Lebenserwartung	0.53	0.48	0.27	0.44	0.44	
politische Polarisierung	-0.45	-0.38	-0.29	-0.43	-0.46	
politische Gewalt	-0.49	-0.42	-0.22	-0.52	-0.54	
Versammlungsfreiheit	0.87	0.91	0.92	0.86	0.73	
Massenmobilisierung	-0.02	0.04	0.15	-0.04	-0.09	
Autokratische Bewegungen	-0.60	-0.58	-0.53	-0.61	-0.56	
Demokratische Bewegungen	-0.09	-0.01	0.18	-0.00	-0.05	
Beteiligung an staatlich organisierten Gruppen	-0.64	-0.62	-0.57	-0.55	-0.50	
Beteiligung an unabhängigen nicht-politischen Gruppen	0.46	0.45	0.49	0.47	0.47	
Freiheit von Forschung und Lehre	0.82	0.86	0.92	0.83	0.71	

- Zu sehen ist eine Kovarianzmatrix. Ein Wert von 1 bedeutet, dass die Werte identisch sind und damit gleichzeitig variieren. Also gleichzeitig steigen oder fallen.
 - Eine negative Kovarianz bedeutet, dass die eine Variable steigt, wenn die andere sinkt, und umgekehrt.
 - 0 bedeutet, dass keine lineare Beziehung zwischen den beiden Variablen besteht.
-
- Diese Infos sind wichtig für die PCA.
 - Wenn zwei Variablen eine hohe Kovarianz haben, dann bedeutet dies, dass sie ähnliche Informationen liefern. Diese beiden Variablen könnten also zu einer einzigen Hauptkomponente zusammengefasst werden.
 - Wenn zwei Variablen kaum korreliert sind (d.h., ihre Kovarianz ist nahe bei null), deutet dies darauf hin, dass sie unterschiedliche Informationen liefern. In diesem Fall kann PCA sie als getrennte Hauptkomponenten behandeln, da sie unterschiedliche Aspekte der Daten erklären.

PCA anwenden

```
In [95]: pca = PCA() # Es wird ein PCA-Objekt erstellt. Berechnet (Eigenvektoren) basierend
pca_t= pca.fit_transform(data_pca_v) # PCA wird auf die standardisierten Daten angewendet
pca_t = pd.DataFrame(pca_t, index=pca_vorbereitung.index) # Erstellung eines neuen DataFrames
pca_t.round(2)
```

```
Out[95]:
```


		0	1	2	3	4	5	6	7	8	9	10	11	12	
	Land														
	Jahr														
	Mexico	1996	-0.84	1.26	-1.02	0.08	-0.94	-0.07	-1.11	-0.33	0.23	-0.14	1.43	-0.69	0.0
		1998	-0.30	1.25	-0.96	-0.05	-1.07	-0.04	-1.04	-0.06	-0.17	-0.06	1.52	-0.66	0.0
		2000	0.62	1.57	-1.00	-0.23	-0.69	-0.07	-1.18	0.57	-0.93	0.20	1.23	-0.46	0.0
		2002	0.91	0.92	-0.70	-0.58	-0.53	0.02	-1.17	0.15	-0.96	-0.07	0.88	-0.29	0.0
		2003	0.65	1.05	-0.77	-0.77	-0.84	-0.14	-1.07	0.14	-1.01	0.14	0.91	-0.26	0.0
	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
	Hungary	2018	-0.00	0.73	-3.00	0.09	-0.67	-1.34	0.40	-0.38	1.61	-0.99	0.42	0.12	-0.0
		2019	0.19	0.03	-2.44	-0.33	-0.22	-1.15	0.82	-0.43	1.30	-0.74	0.16	0.35	-0.0
		2020	0.28	-1.16	-1.51	-0.77	0.28	-0.96	1.51	-0.72	1.02	-0.42	-0.07	0.51	-0.0
		2021	0.06	-1.39	-1.39	-0.62	0.32	-1.00	1.33	-1.02	1.41	-0.31	-0.06	0.29	-0.0
		2022	-0.46	0.77	-3.01	-0.01	-0.70	-1.37	0.69	0.03	1.25	-0.89	0.26	0.28	-0.0

4013 rows × 20 columns

```
In [96]: explained_variance = pca.explained_variance_ratio_  
# pca.explained_variance_ratio_ ist ein Array mit Werten zwischen 0 und 1.  
# Jeder Wert steht für den Anteil der Gesamtvarianz, den eine bestimmte Hauptkompo  
sns.barplot(x=range(1, len(explained_variance)+1), y=explained_variance)  
# (x=range(1, len(explained_variance)+1) --> die X-Achse wird mit 1, 2, 3, ... (stat  
plt.title("Erklärte Varianz pro Hauptkomponente")  
plt.xlabel("Hauptkomponente")  
plt.ylabel("Anteil erklärter Varianz")  
plt.grid(True)  
plt.show()
```

[scatterd] >INFO> Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.

[scatterd] >INFO> Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



- Diese Werte stellen den Anteil der erklärten Varianz pro Hauptkomponente (PC) dar. Die Summe aller Werte ergibt 1 bzw. 100% und zeigt, wie viel Information (Varianz) jede Komponente aus dem ursprünglichen Datensatz erhält.

- Typischerweise wählt man so viele Komponenten, dass 90% der Varianz erklärt sind. In meinem Fall wähle ich die ersten 7 Komponenten (91,7%).
- Die Tatsache, dass die erste Komponente (56%) so dominant ist zeigt, dass viele Variablen korrelieren. Das liegt wahrscheinlich an den Korruptionsindikatoren, die gemeinsam variieren.

Erstellen des Dataframes " data_pca mit den ersten 7 Komponenten

In [146...

```
from pca import pca
pca = pca(n_components=7)

# Fit transform
results = pca.fit_transform(data_pca_v)

#erstellen des Dfs
data_pca = results['PC']
```

```
[pca] >Extracting column labels from dataframe.
[pca] >Extracting row labels from dataframe.
[pca] >The PCA reduction is performed on the [20] columns of the input dataframe.
[pca] >Fit using PCA.
[pca] >Compute loadings and PCs.
[pca] >Compute explained variance.
[pca] >Outlier detection using Hotelling T2 test with alpha=[0.05] and n_componen
ts=[7]
[pca] >Multiple test correction applied for Hotelling T2 test: [fdr_bh]
[pca] >Outlier detection using SPE/DmodX with n_std=[3]
```

Problem: Woher weiß ich was sich hinter den PC1,PC2 etc.. verbirgt?

- Antwort: Loadings. PC1 etc.. sind Eigenvektoren. Diese bestehen aus den Loadings aller Variablen. Die Loadings wiederum sind Gewichte, mit denen jede ursprüngliche Variable zur jeweiligen Hauptkomponente (PC) beiträgt. Sie zeigen, wie stark und in welche Richtung eine Variable den Eigenvektor beeinflusst.

In [147...

```
pca.results['loadings'].round(3)
```

Out[147]:

	Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichkeit(Index)
PC1	0.284	0.273	0.238	0.275	0.265	0.286
PC2	0.095	0.159	0.294	0.115	0.052	-0.016
PC3	-0.010	0.002	0.148	0.047	0.033	-0.020
PC4	-0.010	-0.089	-0.148	0.015	0.153	0.166
PC5	-0.008	-0.047	-0.069	-0.179	-0.147	0.102
PC6	-0.048	-0.035	-0.006	-0.102	-0.128	-0.183
PC7	-0.124	-0.083	-0.073	0.239	0.258	-0.015

- Positive Loadings (z. B. +0.286 für „Rechtsstaatlichkeit“) --> Diese Variablen sind positiv mit PC1 korreliert. Je höher diese Werte im Datensatz, desto stärker wird die Beobachtung entlang der PC1-Achse in positive Richtung verschoben.
- Negative Loadings (z. B. -0.264 für „öffentliche Korruption“) --> Diese Variablen sind negativ mit PC1 korreliert. Je höher der Wert bei diesen Variablen, desto stärker wird die Beobachtung entlang der PC1-Achse in negative Richtung verschoben.

- Ich habe mir die Loadings für alle PC- Komponenten ausgegeben lassen und zusammengefasst:

PC1: Ein hoher PC1-Wert zeigt starke Institutionen, Rechtsstaatlichkeit und geringe Korruption; ein niedriger Wert das Gegenteil.

PC2: Ein hoher PC2-Wert deutet auf Staaten hin, die von aktiven demokratischen Bewegungen, einer freien Meinungsbildung und einer breiten politischen Teilnahme geprägt sind. Ein negativer Wert bedeutet das Gegenteil.

PC3: Ein niedriger PC3-Wert deutet auf Länder mit hoher Fertilität, niedriger Lebenserwartung und geringer gesellschaftlicher Mobilisierung hin, was oft mit weniger entwickelten oder politisch instabileren Staaten in Verbindung gebracht wird. Ein positiver Wert bedeutet das Gegenteil.

PC4: Ein hoher Wert in PC4 bedeutet, in diesen Ländern eine stärkere Teilnahme an staatlich organisierten Gruppen sowie zivilgesellschaftlichen Aktivitäten zu finden ist, die mit weniger Korruption einhergeht.

PC5: Ein hoher PC5-Wert steht für Länder, in denen politische Gewalt und Polarisierung besonders ausgeprägt sind. Diese Länder befinden sich vermutlich in einem Zustand tiefer politischer Fragmentierung oder sogar in einer Krise. Ein niedriger PC5-Wert zeigt Länder mit stärkerer Einbindung der Bevölkerung in organisierte Strukturen, weniger politischer Gewalt und geringerer Polarisierung.

PC6: Ein hoher PC6-Wert deutet auf Länder mit starkem Engagement in nicht-politischen zivilgesellschaftlichen Bereichen hin, begleitet von relativ hoher Lebenserwartung und möglicherweise schwächer ausgeprägter politischer Beteiligung. Es handelt sich um Gesellschaften mit sozialer Stabilität, aber ohne zwingend starke oder demokratisch legitimierte politische Institutionen.

PC7: Ein hoher PC7-Wert zeigt Staaten mit starker ideologischer Polarisierung innerhalb der Gesellschaft, oft trotz oder gerade wegen gut funktionierender Institutionen. Dies könnte auf „gespaltene Demokratien“ hinweisen – etwa reife Demokratien mit zunehmendem Populismus, Identitätspolitik oder Lagerbildung. Ein niedriger PC7-Wert hingegen kennzeichnet Länder mit stärkerer autoritärer Kontrolle, weniger gesellschaftlicher Spaltung, aber auch geringerer öffentlicher Beteiligung und eher technokratischer oder repressiver Stabilität.

Task 6 -- Clustering

Choice of Algorithm: Given the situation in the pitch and the results from the above analyses. Which algorithm (chosen from those discussed in the lectures) would YOU choose for the clustering? Explain! (Choice + 1-3 bullet points in the cell below)

My Choice: ...

- Ich würde ein soft Clustering (EM (Gaussian Mixture Model - (Vorlesung 11))) wählen. (Auch wenn wir dieses Clustering nicht in diesem Portfolio nutzen sollen) Die Beobachtungen des Vdem-Datensatzes lassen sich nicht eindeutig in ein kugelförmiges Cluster überführen und lassen sich mit bloßem Auge auch nur sehr schwer einem Cluster zuordnen. Der Hintergrund könnte sein, dass sich viele Länder in einer Transformation befinden (Demokratie --> Autokratie).
- Aus diesem Grund können Merkmale je Land stark variieren und sind volatil, weshalb ein "weiche Zuordnung" angebracht ist.
- Außerdem weisen viele Variablen auf einen Zusammenhang mit der politischen Stabilität hin. Weshalb ich eher elliptische Cluster erwarte.
- Zudem weisen die Länder wahrscheinlich Merkmale mehrerer Typen auf. Wenn ein Land politisch korrupt ist, dann ist wahrscheinlich auch die executive korrupt, sowie die Öffentlichkeit. --> GMM erlaubt Wahrscheinlichkeiten.

Requirements: In the following and for the remainder of the final phase of the exam (independent of what your choice above suggests), use * a clustering algorithm \$A\$, chosen from the family: `__k-means/k-means++__` * the evaluation metric \$E_1\$: `__Silhouette Score__` * the evaluation metric \$E_2\$: `__Davies-Bouldin Index__`.

```
In [99]: from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score
from sklearn.datasets import make_blobs
from sklearn.preprocessing import StandardScaler
```

Comprehensive clustering analysis

Clustering: On both datasets, `data` and `data_pca`, under their respective headlines below, conduct comprehensive clustering analyses with algorithm \$A\$, using the available methodology from the module and specifically \$E_1\$ and \$E_2\$. Conduct ALL necessary steps to create the most helpful and meaningful clustering per dataset and discuss its quality. Use appropriate diagrams to demonstrate the results. (Commented code + bullet points, add cells)

Clustering Analysis of plain data

K-Means

```
In [100... # Die Spalten Land und Jahr sollten als index genutzt werden (bei allen Clustering)
# Diese sollte keinen Einfluss auf das Clustern nehmen. Das gilt für alle Clustering
Data_plain = Data_ohne_pS.set_index(['Land', 'Jahr'])
```

```
In [101... # da ich mehrere features mit unterschiedlich hohen Metriken habe, muss ich alle k
# --> hohe Werte würden sonst die Clusterbildung dominieren.
scaler = StandardScaler()
X = scaler.fit_transform(Data_plain)
# fit() berechnet Mittelwert und Standardabweichung für jede Spalte, transform() s
```

```
In [102... # ich möchte mehrere K ausprobieren und das beste Cluster auswählen.
# Erstellen Leerer Listen um die Ergebnisse zu speichern.
silhouette_scores = []
db_scores = []
k_values = range(2, 11) # k = 2 bis 10

# Schleife für verschiedene k
for k in k_values:
    kmeans_plain = KMeans(
        n_clusters=k,
        init='k-means++', # es ändert sich nichts an E1 und E2, wenn ich random e
        n_init= 20, # es ändert sich nichts E1 und E2, wenn man n_init höher ode
        max_iter= 300, # wenn max_iter z.B. = 1 bzw. sehr klein ist, verschlechter
        tol= 0.0001, # Je höher tol, desto schlechter E1 und E2. Merkllich aber ers
        random_state= 42
    )

    cluster_assignments1 = kmeans_plain.fit_predict(X)

    # speichert den berechneten silhouette_score und davies_bouldin_score in den l
    sil = silhouette_score(X, cluster_assignments1)
    db = davies_bouldin_score(X, cluster_assignments1)

    silhouette_scores.append(sil)
    db_scores.append(db)
```


```
In [103... print(silhouette_scores)
print(db_scores)

[0.3401012819173013, 0.269487140695397, 0.2512390023125907, 0.23089466126925112,
0.2059969638585119, 0.20712546940437557, 0.18686338746973769, 0.1893266681695665,
0.18952802359443932]
[1.0875744907757732, 1.4777907714952858, 1.4761416070153701, 1.6378165218012293,
1.6818959984514337, 1.6928368807895435, 1.6460952550261567, 1.6715693199079082,
1.648255619166487]
```

In [104...

```
# Plot Silhouette-Score
plt.figure(figsize=(12, 5))
plt.plot(k_values, silhouette_scores, marker="o")
plt.title("Silhouette-Score (E1) über k")
plt.xlabel("Anzahl Cluster (k)")
plt.ylabel("Silhouette-Score")
plt.grid(True)
plt.show()

# Plot Davies-Bouldin-Index
plt.figure(figsize=(12, 5))
plt.plot(k_values, db_scores, marker="o")
plt.title("Davies-Bouldin Index (E2) über k")
plt.xlabel("Anzahl Cluster (k)")
plt.ylabel("Davies-Bouldin Index")
plt.grid(True)
plt.show()
```



Interpretation und Schlussfolgerungen bezüglich der Clusterqualität

- Ich habe verschieden viele Cluster (von 2 - 10) ausprobiert: Die Einstellung "2 Cluster" liefert die besten Ergebnisse. Dies gilt sowohl für den Silhouette-Scores als auch für den Davies-Bouldin Index.
- Ein Davies-Bouldin Index von 1.0876 deutet auf eine mäßige bis gute Clusterqualität hin. Je kleiner der Wert, desto geringer ist die Streuung innerhalb der Cluster.
- Der Silhouette-Score misst die Kohäsion (Wie nah sind Punkte an anderen im gleichen Cluster?) und die Separation (Wie weit sind sie von Punkten im nächsten Cluster entfernt?). Je höher der Wert, desto besser. In diesem Kontext bedeutet ein Wert von 0.3401, dass eine Clusterstruktur vorhanden ist. Diese ist jedoch nicht ideal, weshalb es überlappende bzw. unscharfe Grenzen zwischen den Clustern gibt.
- Die Tatsache, dass nur 2 Cluster die besten Ergebnisse liefern, scheint daran zu liegen, dass sich die Daten entlang eines zweidimensionalen Spektrums am besten gruppieren lassen. Es handelt sich um ein Spektrum, welches Länder vermutlich von liberal demokratisch hin zu autoritär korrupt sortiert.
- Neben der Clusteranzahl beeinflussen Parameter wie `init`, `n_init`, `max_iter` und `tol` das KMeans-Ergebnis. `init` bestimmt die Startmethode der Zentren, „k-means++“ ist meist besser als zufällig. Dies ändert hier aber nichts. `n_init` legt fest, wie oft mit verschiedenen Startpunkten neu gestartet wird, was die Ergebnisqualität verbessert. Macht hier aber auch keinen Unterschied. `max_iter` begrenzt die maximale Anzahl an Iterationen: zu klein kann zu ungenauen Clustern führen. `tol` definiert die Abbruchschwelle für die Konvergenz: ein zu hoher Wert kann die Qualität verschlechtern, ein zu niedriger verlängert die Laufzeit.
- Vorzüge Kmeans:

K-means ist gut bei „runden“ Clustern. Wenn sich Cluster wirklich als kugelförmige Gruppen im Raum verteilen, liefert K-means sehr präzise Ergebnisse. Bei länglichen Clustern, wie es hier zu erwarten ist, könnten jedoch verzerrte Ergebnisse entstehen. Der DB und der Silhouette-Score wiesen hier immerhin auf eine insgesamt mittlere bis mäßige Qualität hin. Die Cluster sind daher wahrscheinlich nicht so richtig kugelförmig.

Ferner wird jeder Punkt eindeutig einem Cluster zugewiesen, was ein Vorteil ist, da keine Rauschpunkte gibt.

Weiterhin werden die Zentren so gewählt, dass die Summe der quadrierten Abstände innerhalb jedes Clusters minimal wird. Dadurch tendieren die Cluster aber auch dazu, etwa gleich groß (in Datenpunkten) zu sein, sofern die Verteilung der Punkte halbwegs homogen ist. --> hier sind die Cluster nicht wirklich gleich groß, weshalb die Verteilung wohl auch nicht so wirklich homogen ist.

Clustering Analysis of PCA transformed data

K-means

In [105...

```

silhouette_scores = []
db_scores = []
k_values = range(2, 11) # k von 2 bis 10

for k in k_values:
    kmeans_pca = KMeans(
        n_clusters=k,           # Es gilt das Gleiche wie oben.
        init='k-means++',      # 'random' verändert die Scores kaum.
        n_init=20,             # Mehrfache Initialisierungen für stabilere Ergebnisse
        max_iter=300,          # max_iter zu klein = schlechtere Scores
        tol=0.0001,            # toleranz zu hoch = schlechtere Scores
        random_state=42
    )

    cluster_assignments2 = kmeans_pca.fit_predict(data_pca) # Clustern auf PCA-Daten

    sil = silhouette_score(data_pca, cluster_assignments2) # Silhouette-Score berechnen
    db = davies_bouldin_score(data_pca, cluster_assignments2) # Davies-Bouldin-Index berechnen

    silhouette_scores.append(sil)
    db_scores.append(db)

```

In [106...

```

print(silhouette_scores)
print(db_scores)

```

```


[0.3703159581294548, 0.3004575721806981, 0.28500014160438536, 0.26203551904203265,
 0.2417979483626299, 0.24148950521925042, 0.2231856441085952, 0.22574039232596,
 0.22597807957036006]
[1.001285823717011, 1.3342656293334623, 1.3141169450132444, 1.4422948802507614, 1.4656635004351124,
 1.506949655896556, 1.453492769127903, 1.479441694381538, 1.4330915670610578]

```

In [107...

```
# Plot Silhouette-Score
plt.figure(figsize=(12, 5))
plt.plot(k_values, silhouette_scores, marker="o")
plt.title("Silhouette-Score (E1) über k")
plt.xlabel("Anzahl Cluster (k)")
plt.ylabel("Silhouette-Score")
plt.grid(True)
plt.show()

# Plot Davies-Bouldin-Index
plt.figure(figsize=(12, 5))
plt.plot(k_values, db_scores, marker="o")
plt.title("Davies-Bouldin Index (E2) über k")
plt.xlabel("Anzahl Cluster (k)")
plt.ylabel("Davies-Bouldin Index")
plt.grid(True)
plt.show()
```



- Ebenso wie beim Clustering mit den plain Daten liefert die Einstellung "2 Cluster" die besten Ergebnisse.
- Sowohl E1 als auch E2 haben sich jedoch leicht verbessert gegenüber dem Cluster ohne PCA. (E1: 0.37883411628623176, E2:1.001)
- PCA hilft dem algorithmus also tatsächlich beim Clustern, indem es die Daten auf die relevantesten Hauptkomponenten, die den Großteil der Varianz erklären, reduziert.

Task 7 -- Clustering Comparison

Comparison: Compare both clustering from the previous task as described in Task 7. (Commented code + bullet points, add cells below)

- Die Anzahl der Cluster ist sowohl beim Clustern mit PCA als auch beim Clustern ohne PCA identisch. $n = 2$ (bezüglich Kmeans)
- Rauschpunkte: K-Means zwingt jede Datenpunktzugewandung zu einem Cluster. Jeder Punkt wird dem nächstgelegenen Clusterzentrum (nach euklidischer Distanz) zugewiesen. Daher gibt es keine Rauschpunkte.
- Silhouette-Score (E1) (Je höher desto besser): Ohne PCA: 0.3401012819173013, mit PCA: 0.3703159581294548 --> Auch wenn K-Means kein Rauschen erkennt, kann es von „störenden Informationen“ in den Daten beeinflusst werden. Manche Variablen tragen wenig zur Clusterstruktur bei. Diese Variablen wirken dann wie Rauschen im Feature-Sinn und fügen unnötige Komplexität hinzu und verzerren dadurch die Clusterzentren. PCA hilft dabei, diese störenden Effekte zu reduzieren, indem die Dimensionen reduziert werden.
- Davies-Bouldin Index (E2) (je niedriger desto besser): Ohne PCA: 1.0875744907757732, mit PCA: 1.001285823717011 --> Mit PCA ist der Wert niedriger. Die Cluster sind also kompakter (Distanzen innerhalb der Cluster kleiner) und/oder besser voneinander getrennt (größere Abstände zwischen Clustern). Ich denke, dass der gleiche Grund dafür verantwortlich ist.

Insgesamt ist der Unterschied bei E1 und E2 nicht riesig, aber spürbar. PCA hilft, die Clusterstruktur zu verbessern, auch wenn beide Clusteralgorithmen ergeben, dass es keine sehr klar trennbaren Cluster gibt.

Dateninstanzen

- ich möchte einen Crosstab erstellen. Dieser soll zeigen ob die gleichen Instanzen in den gleichen Clustern gelandet sind. (Instanzvergleich zwischen PCA-Clustern und ohne-PCA-Clustern)

In [110...

```
# Damit ich die Clusterings nach ihren Instanzverteilungen vergleichen kann, muss
# Ansonsten würde k = 10 aufgrund der Schleife genutzt werden.

# Clustering ohne PCA (k=2)
kmeans_plain = KMeans(n_clusters=2,
                      init='k-means++',
                      n_init=20,
                      max_iter=300,
                      tol=0.0001,
                      random_state=42 )
cluster_assignments1 = kmeans_plain.fit_predict(X)

# Clustering mit PCA (k=2)
kmeans_pca = KMeans(n_clusters=2,
                   init='k-means++',
                   n_init=20,
                   max_iter=300,
                   tol=0.0001,
                   random_state=42)
cluster_assignments2 = kmeans_pca.fit_predict(data_pca)

# erstellen eines DF für den Vergleich
df_clusters = pd.DataFrame({
    'Cluster_ohne_PCA': cluster_assignments1,
    'Cluster_PCA': cluster_assignments2
})

# erstellen eines crosstabs.
# Da K-Means keine echte „Cluster-Bedeutung“ kennt, kann Cluster 0 genauso gut Clu
# Das ist bei mir passiert. .map({0: 1, 1: 0}) sorgt dafür, dass bei dem Cluster c
cluster_vergleich = pd.crosstab(df_clusters["Cluster_ohne_PCA"].map({0: 1, 1: 0}),
                                df_clusters["Cluster_PCA"].map({0: 1, 1: 0}))
print(cluster_vergleich)
```

Cluster_PCA	0	1
Cluster_ohne_PCA		
0	1590	0
1	3	2420

- 1590 Instanzen sind in Cluster 0 bei beiden Clustern (ohne und mit PCA).
- 2420 Instanzen sind in Cluster 1 bei beiden Clustern.
- Nur 3 Instanzen wurden unterschiedlich zugeordnet. Das sind unter 0.5% der Daten.

-->Die Cluster ohne PCA und die Cluster mit PCA sind fast identisch in ihrer Zuordnung der Dateninstanzen. Die Cluster-Ergebnisse sind also vergleichbar. Das PCA-Clustering hat kaum etwas verändert. Vielmehr hat es nur die Struktur etwas verbessert und unterstützt.

Task 8 -- Conclusions and Future Work

Subtasks: For each subtask, create a fitting headline and add additional code and markdown cells below to conduct the respective task. (Commented code + bullet points, add cells below)

Nr 1) wahl des Clusters

- Ich wähle das Cluster-Ergebnis mit PCA (also das Clustering, das auf den Hauptkomponenten basiert) und Algorithmus A (Kmeans++) als Endergebnis aus.
- Begründung:

Bessere Clusterbewertung: Der Silhouette-Score des PCA-basierten Clusters ist mit 0.3703 höher als der des Clusters ohne PCA (0.3401). Der Davies-Bouldin Index ist bei der PCA-Variante mit 1.0013 niedriger als ohne PCA (1.0876).

Ebenso sind die Ergebnisse dieses Algorithmus auch besser als die Ergebnisse von den Algorithmusfamilien b) (DBSCAN) und c) (HAC). Bei DBSCAN, habe ich zudem nur sehr kleine Cluster erhalten und konnte den Ketteneffekt nicht loswerden. HAC lieferte ein Ergebnis, welches dem von Kmeans nahe kam. Das Dendrogramm sorgte zudem für einen guten Einblick in die hierarchische Clusterstruktur. Dennoch fiel der Silhouette-Score und der Davies-Bouldin Index etwas schlechter aus.

Dimensionalitätsreduktion: PCA reduziert die Dimensionen quasi auf die wichtigsten Komponenten, wodurch die irrelevante Variabilität minimiert wird. Dadurch kann der Clustering-Algorithmus klarere Cluster erkennen.

Nr 2) Diskussion der Clustermerkmale.

- Da ich nun schon häufiger auf die Merkmale zur Clusterqualität eingegangen bin gehe ich hier davon aus, dass es in dieser Aufgabe um die Interpretation und den Vergleich der Merkmale bezüglich der Variablen der Cluster geht.
- Ferner habe ich die Mittelwerte aller Algorithmen ausversehen schon in der Draft Stage unter Aufgabe 6 dargestellt. (Nicht genau gelesen). Das werde ich hier einfach wiederholen.
- (Eine Interpretation der Merkmale in den Clustern ist noch nicht notwendig, dies folgt später in Aufgabe 8) --> Ich hoffe, dass ich diese Anweisung richtig verstehe)

Mittelwerte der Features je Cluster vergleichen:

plain data:

Kmeans ohne PCA:

```
In [111... # hinzufügen der Zielvariable. Die Indexe müssen dafür gleich sein!
# Ich benötige die politische Stabilität aus Data.
Data.set_index(["Land", "Jahr"], inplace=True)

In [112... # Ich benötige die standardisierten Daten als DF.
X_kmean = pd.DataFrame(X, columns=Data_plain.columns, index=Data_plain.index)

In [113... # Diesem Df möchte ich die eine Clusterzuordnung hinzufügen.
X_kmean['Cluster'] = cluster_assignments1

In [114... # Analyse der Mittelwerte je feature + Vergleich der Zielvariable.
cluster_means = X_kmean.groupby('Cluster').mean()
cluster_means
```


Out[114]:

	Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichkeit(In
Cluster						
0	-0.685872	-0.650398	-0.513057	-0.593659	-0.580826	-0.67
1	1.045200	0.991141	0.781848	0.904676	0.885120	1.03

In [116...

```
# Transponieren für bessere Darstellung im Barplot
cluster_mean1 = cluster_means.T

# Barplot erstellen
cluster_mean1.plot(kind="bar", figsize=(12, 6))
plt.title("Durchschnittswerte der politischen Faktoren je Cluster")
plt.xlabel("politische Faktoren")
plt.ylabel("Durchschnittlicher Wert")
plt.xticks(rotation=90)
plt.legend(title='Cluster')
plt.grid()
plt.show()
```



- Die Grafik zeigt deutliche Gegensätze zwischen den beiden Clustern hinsichtlich der erklärenden Variablen.
- So lässt sich erkennen, dass der größte Unterschied zwischen den Clustern in der Variable der liberalen Demokratie, der Rechtsstaatlichkeit, der fairen und freien Wahlen und in den Korruptionsvariablen liegt.
- In Cluster 0 sind Länder mit durchschnittlich niedrigen Werten bezüglich der liberalen Demokratie, der Rechtsstaatlichkeit und der fairen und freien Wahlen. Diese Länder haben folglich schlecht ausgeprägte politische Institutionen. Die Werte bezüglich ihrer Korruption sind jedoch hoch.
- In Cluster 1 befinden sich Länder, die gegenteilige Ausprägungen aufweisen. Diese Länder genießen liberale Demokratie, Rechtsstaatlichkeit und freie und faire Wahlen. Gleichzeitig spielt Korruption keine Rolle.

pca data kmeans

```
In [122... data_pca_Kmeans = data_pca.copy()
data_pca_Kmeans["Cluster"] = cluster_assignments2 # ClusterLabels


# hinzufügen von politischer Stabilität
data_pca_Kmeans["politische Stabilität"] = Data["politische Stabilität"]

# Vergleich der Mittelwerte je Feature und Cluster
mittelwerte_Kmeans_pca = data_pca_Kmeans.groupby("Cluster").mean()
mittelwerte_Kmeans_pca
```

```
Out[122]:
```

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	politische Stabilität
Cluster								
0	3.515143	-0.135493	-0.101396	0.038756	0.044440	-0.078780	-0.028443	0.589006
1	-2.313894	0.089190	0.066745	-0.025512	-0.029254	0.051858	0.018723	-0.675224

```
In [123... # Barplot erstellen
mittelwerte_Kmeans_pca.plot(kind="bar", figsize=(12, 6))
plt.title("Durchschnittswerte der PCA-Komponenten je Cluster")
plt.xlabel("PCA-Komponenten")
plt.ylabel("Durchschnittlicher Wert")
plt.xticks(rotation=45)
plt.legend(title='Cluster')
plt.grid()
plt.show()
```



Um zu verstehen, was die Mittelwerte aussagen müssen wir verstehen, welche Variablen in den Komponenten 1-7 dominieren. Dafür nutzt man die Loadings (siehe Aufgabe 5). Zur Erinnerung: PC1 erklärt 56% der Varianz.

PC1: Ein hoher PC1-Wert zeigt starke Institutionen, Rechtsstaatlichkeit und geringe Korruption; ein niedriger Wert das Gegenteil.

PC2: Ein hoher PC2-Wert deutet auf Staaten hin, die von aktiven demokratischen Bewegungen, einer freien Meinungsbildung und einer breiten politischen Teilnahme geprägt sind. Ein negativer Wert bedeutet das Gegenteil.

PC3: Ein niedriger PC3-Wert deutet auf Länder mit hoher Fertilität, niedriger Lebenserwartung und geringer gesellschaftlicher Mobilisierung hin, was oft mit weniger entwickelten oder politisch instabileren Staaten in Verbindung gebracht wird. Ein positiver Wert bedeutet das Gegenteil.

PC4: Ein hoher Wert in PC4 bedeutet, in diesen Ländern eine stärkere Teilnahme an staatlich organisierten Gruppen sowie zivilgesellschaftlichen Aktivitäten zu finden ist, die mit weniger Korruption einhergeht.

PC5: Ein hoher PC5-Wert steht für Länder, in denen politische Gewalt und Polarisierung besonders ausgeprägt sind. Diese Länder befinden sich vermutlich in einem Zustand tiefer politischer Fragmentierung oder sogar in einer Krise. Ein niedriger PC5-Wert zeigt Länder mit stärkerer Einbindung der Bevölkerung in organisierte Strukturen, weniger politischer Gewalt und geringerer Polarisierung.

PC6: Ein hoher PC6-Wert deutet auf Länder mit starkem Engagement in nicht-politischen zivilgesellschaftlichen Bereichen hin, begleitet von relativ hoher Lebenserwartung und möglicherweise schwächer ausgeprägter politischer Beteiligung. Es handelt sich um Gesellschaften mit sozialer Stabilität, aber ohne zwingend starke oder demokratisch legitimierte politische Institutionen.

PC7: Ein hoher PC7-Wert zeigt Staaten mit starker ideologischer Polarisierung innerhalb der Gesellschaft, oft trotz oder gerade wegen gut funktionierender Institutionen. Dies könnte auf „gespaltene Demokratien“ hinweisen – etwa reife Demokratien mit zunehmendem Populismus, Identitätspolitik oder Lagerbildung. Ein niedriger PC7-Wert hingegen kennzeichnet Länder mit stärkerer autoritärer Kontrolle, weniger gesellschaftlicher Spaltung, aber auch geringerer öffentlicher Beteiligung und eher technokratischer oder repressiver Stabilität.

- Was bedeuten die Cluster?

Cluster 0: ist ein Cluster von stabilen Demokratien mit starken Institutionen, niedriger Korruption, aber mäßigem zivilgesellschaftlichem Engagement und geringer politischer Mobilisierung.

Cluster 1: ist ein Cluster von Ländern mit schwachen politischen Institutionen und einer eher starken Korruption, mit einer gleichzeitig eaktiveren Zivilgesellschaft und politischer Mobilisierung. Diese Staaten befinden sich eventuell in Transformationsprozessen oder in autoritären Phasen.

Hinsichtlich der Zielvariable lässt sich ein deutlicher Unterschied erkennen, der zusammen mit PC1 variiert.

Zusammenfassende Schlussfolgerung bezüglich des vergleichs der Mittelwerte:

Beide Clusteranalysen haben auf Basis ähnlicher ursprünglicher Variablen die Länder in mehr oder weniger gleiche Gruppen eingeteilt. Auch wenn die PCA Methode zuerst Eigenvektoren auf Basis von den ursprünglichen Variablen bildet sind die inhaltlichen bedeutungen der Variablen für die Einteilungen in die Cluster ähnlich. Wie man auch an dem Vergleich der Dateninstanzen sehen konnte.

plain data DBSCAN

In [127...

```
from sklearn.cluster import DBSCAN

# Cluster mit DBSCAN --> siehe: Hilfe zum Bestimmen der Parameter:
dbscan = DBSCAN(
    eps= 3,                # Radius
    min_samples= 25,       # Mindestanzahl von Punkten im eps-Umkreis
    metric='minkowski',    # Distanzmaß (hier euklidische Distanz)
    metric_params=None,    # Zusätzliche Parameter für die Distanzfunktion (nicht
    algorithm='auto',      # Algorithmus zur Suche
    leaf_size=50,          # Blattgröße für Baum-Strukturen zur Optimierung (relev
    p= 1.5 ,               # Parameter für Minkowski-Metrik (nicht relevant bei 'e
    n_jobs=-1
)

# DBSCAN auf standardisierten Daten X ausführen
dbscan_clusters = dbscan.fit_predict(X) # X ist der standardisierter Datensatz (D

# Ausgabe Clusterlabels:
# -1 kennzeichnet Punkte, die als Rauschen (Noise) eingestuft wurden,
print(np.unique(dbscan_clusters))

[-1  0  1  2  3  4  5]
```

```
In [128... X_DBSCAN = pd.DataFrame(X, columns=Data_plain.columns, index=Data_plain.index)
X_DBSCAN["Cluster"] = dbscan_clusters # Clusterlabels

# hinzufügen von politischer Stabilität
X_DBSCAN["politische Stabilität"] = Data["politische Stabilität"]

# Vergleich der Mittelwerte je Feature und Cluster
cluster_means = X_DBSCAN.groupby("Cluster").mean()
cluster_means
```

Out[128]:

	Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichkeit(In
Cluster						
-1	-0.703984	-0.724807	-0.718912	-0.652982	-0.529871	-0.51
0	0.321605	0.347822	0.372911	0.306802	0.247179	0.23
1	-1.170121	-1.459756	-1.741954	-1.167210	-0.992601	-0.82
2	-1.097881	-1.625272	-1.988019	-0.376888	0.254485	0.13
3	-1.261881	-1.214303	-1.618612	-1.402945	-1.501029	-1.52
4	-1.315762	-1.378707	-1.936080	-1.840102	-1.552591	-1.47
5	-1.334528	-1.886046	-1.956173	-1.848384	-1.372020	-0.79

Cluster0: Cluster 0 ist ein großes Cluster, was sich entlang des Spektrums erstreckt. Es beinhaltet im Schnitt leicht überdurchschnittlich starke Demokratiewerte und leicht überdurchschnittliche Freiheits- und Lebenswerte, eine geringe Korruption, eine moderate Mobilisierung und insgesamt stabile Verhältnisse. --> Ist meiner Meinung nach durch den Ketteneffekt verzerrt.

Cluster 1: besteht wahrscheinlich aus Autokratien – schlechte liberale Werte, etwas Korruption, starke autokratische Bewegungen, etwas instabil.

Cluster 2: wahrscheinlich Repressive, aber gefestigte Regime – extrem niedrige Demokratiewerte, wenig Korruption, hohe Gewalt und Autokratie-Mobilisierung, paradox positiv bei politischer Stabilität.

Cluster 3: sehr niedrige Freiheits- und Justizwerte, extrem hohe Korruption, wenig offene Gewalt, politisch fragil.

Cluster 4: schwache Institutionen, sehr hohe Massen- und Protestmobilisierung (auto- und demokratisch), etwas instabil.

Cluster 5: schlechte DemokratieWerte, mäßige Korruption, kaum Mobilisierung oder Gewalt; politisch lethargisch und repressiv, recht instabil.

Die Cluster weisen interessante Eigenschaften auf. Diese sind jedoch mit Vorsicht zu genießen, da sich nicht allzu viele unterschiedliche Länder in den kleineren Clustern befinden.

DBSCAN mit PCA

In [131...

```
dbscan = DBSCAN(
    eps= 2.5,           # Radius
    min_samples= 20,    # Mindestanzahl von Punkten im eps-Umkreis
    metric='minkowski', # Distanzmaß (hier euklidische Distanz)
    metric_params=None, # Zusätzliche Parameter für die Distanzfunktion (nicht
    algorithm='auto',   # Algorithmus zur Suche
    leaf_size=50,       # Blattgröße für Baum-Strukturen zur Optimierung (relev
    p= 1.5,             # Parameter für Minkowski-Metrik (nicht relevant bei 'e
    n_jobs=-1           # Nutzt alle verfügbaren CPU-Kerne für parallele Berech
)

# DBSCAN auf standardisierten Daten X ausführen
dbscan_clusters2 = dbscan.fit_predict(data_pca) # data_pca ist schon standardisie

# Ausgabe aller unterschiedlichen Clusterlabels:
# -1 kennzeichnet Punkte, die als Rauschen (Noise) eingestuft wurden,
print(np.unique(dbscan_clusters2))
```

```
[-1  0  1  2  3  4  5]
```

In [132]:

```

data_pca_DBSCAN = data_pca.copy()
data_pca_DBSCAN["Cluster"] = dbscan_clusters2 # Clusterlabels

# hinzufügen von politischer Stabilität
data_pca_DBSCAN["politische Stabilität"] = Data["politische Stabilität"]

# Vergleich der Mittelwerte je Feature und Cluster
mittelwerte_DBSCAN_pca = data_pca_DBSCAN.groupby("Cluster").mean()
mittelwerte_DBSCAN_pca

```

Out[132]:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	politische Stabilität
Cluster								
-1	-4.216431	-0.308958	0.195157	0.725761	1.651806	-0.911859	-0.576248	-1.639208
0	0.108371	0.102661	0.022286	-0.037751	0.014547	0.020563	0.006431	-0.174931
1	-6.508871	-3.857180	-2.468497	0.811934	-2.246757	-1.555826	-1.425306	-0.234750
2	-1.774674	-2.250687	-1.160580	0.644357	-0.591533	-0.603077	1.790810	0.211300
3	-2.681519	-2.474960	0.613540	2.799275	0.166577	-0.844854	0.243777	-0.443429
4	-5.349661	-4.307488	-0.383997	-0.237138	-1.833383	0.254307	-1.695132	0.077958
5	2.398212	-4.064962	-0.511509	1.809842	0.426131	0.134306	0.952368	1.269417

Ich möchte hier nicht auf alle PC Mittelwerte je Cluster eingehen. Nur auf PC1, da dieser 56 % der Varianz der Daten erklärt und damit besonders wichtig ist. PC1: Ein hoher PC1-Wert zeigt starke Institutionen, Rechtsstaatlichkeit und geringe Korruption; ein niedriger Wert das Gegenteil.

Cluster 0: Cluster Null erstreckt sich über fast das gesamte Spektrum. Es ist kein wirkliches Cluster, sondern ein Querschnitt der Restlichen Länder.

Ansonsten unterscheiden sich die Werte bezüglich PC1 stark, was auf große Unterschiede zwischen den Clustern hindeutet. Die Tatsache, dass die Cluster klein sind macht dies jedoch wahrscheinlicher. Bezüglich der Zielvariable gilt scheinbar nur, dass eine positiver PC1 Wert mit einer politischen Stabilität einher geht. Ein niedriger PC1- Wert jedoch nicht zwangsläufig mit einer sehr geringen politischen Stabilität.

HAC ohne PCA

In [133...

```
from sklearn import cluster
from scipy.cluster.hierarchy import dendrogram
from scipy.cluster import hierarchy

# Clustern mit HAC
agg = cluster.AgglomerativeClustering(
    n_clusters = 2,          # Angabe wie viel Cluster ich am Ende erhalten möchte
    metric='manhattan',      # Distanzmaß
    linkage='average',       # Linkage-Kriterium: Distanz zweier Cluster average
    compute_distances=True   # speichert die Distanzen während des Merge-Prozesses
                             # → nötig, um später ein Dendrogramm zu zeichnen
)

Cluster_HAC = agg.fit_predict(X) # X = Data_plain standardisiert

X_HAC = pd.DataFrame(X, columns=Data_plain.columns, index=Data_plain.index)
X_HAC["Cluster"] = Cluster_HAC # Clusterlabels

# hinzufügen von politischer Stabilität
X_HAC["politische Stabilität"] = Data["politische Stabilität"]

# Vergleich der Mittelwerte je Feature und Cluster
mittelwerte_HAC = X_HAC.groupby("Cluster").mean()
mittelwerte_HAC
```

Out[133]:

	Liberaler Demokratie (Index)	Wahlen (Index)	Meinungs- und Informationsfreiheit (Index)	Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)	Zugang zur Justiz	Rechtsstaatlichkeit(In
Cluster						
0	-0.697027	-0.659952	-0.523430	-0.599844	-0.589010	-0.67
1	1.042506	0.987056	0.782866	0.897155	0.880951	1.00

Cluster 1 – Liberale Demokratien mit stabiler Ordnung Dieses Cluster zeigt stark positive Werte bei Demokratie, Rechtsstaatlichkeit, Meinungsfreiheit und Gleichheit vor dem Gesetz. Die Korruption ist deutlich negativ, was für ein hohes Maß an Integrität staatlicher Institutionen spricht. Die Lebenserwartung ist überdurchschnittlich, die Fertilitätsrate niedrig. Das ist typisch für entwickelte Länder. Politische Gewalt und Polarisierung sind gering, die Versammlungsfreiheit hoch. --> Aufgrund dieser Merkmale ist die politische Stabilität dieses Clusters hoch.

Cluster 0 – Autokratische, instabilere Systeme mit hoher Korruption Die Demokratiewerte sind stark negativ, ebenso Rechtsstaatlichkeit und bürgerliche Freiheiten. Gleichzeitig ist die Korruption in allen Formen erhöht. Die Lebenserwartung ist unterdurchschnittlich, die Fertilität höher. Politische Gewalt, Polarisierung und autokratische Bewegungen sind klar positiv ausgeprägt.

→ Aufgrund dieser Merkmale ist die politische Stabilität dieses Clusters niedriger

HAC mit PCA

In [134]...

```
# Clustern mit HAC
agg = cluster.AgglomerativeClustering(
    n_clusters = 2, # Angabe wie viel Cluster ich am Ende erhalten möchte.
    metric='euclidean', # Distanzmaß
    linkage='complete', # Linkage-Kriterium: Distanz zweier Cluster averaged
    compute_distances=True # speichert die Distanzen während des Merge-Prozess
                           # → nötig, um später ein Dendrogramm zu zeichnen
)

Cluster_HAC2 = agg.fit_predict(data_pca) # standardisiert

# Ausgabe der Mittelwert + Zielvariable
data_pca_HAC2 = data_pca.copy()
data_pca_HAC2["Cluster"] = Cluster_HAC2
data_pca_HAC2["politische Stabilität"] = Data["politische Stabilität"]
cluster_means3 = data_pca_HAC2.groupby('Cluster').mean()
cluster_means3
```

Out[134]:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	politische Stabilität
Cluster								
0	-2.407951	0.209068	-0.006680	-0.011336	-0.061417	0.072560	0.027664	-0.720260
1	3.148753	-0.273388	0.008735	0.014824	0.080312	-0.094884	-0.036175	0.541757

Hinsichtlich der Zielvariable und auch hinsichtlich PC1 lässt sich ein starker Unterschied zwischen den Clustern erkennen. Auch hier erklärt PC1 die politische Stabilität gut.

Korrelation mit der Zielvariable (politische Stabilität):

plain Data - generell

```
In [136... X_Korr= pd.DataFrame(X, columns=Data_plain.columns, index=Data_plain.index)
```


```
In [137... # hinzufügen von politischer Stabilität für die Korrelation.
X_Korr["politische Stabilität"] = Data["politische Stabilität"]
```

```
In [139... # Korrelationen
correlation1 = X_Korr.corr()["politische Stabilität"].drop("politische Stabilität")
correlation1
```

```
Out[139]: Liberale Demokratie (Index)                0.612404
Wahlen (Index)                0.545407
Meinungs- und Informationsfreiheit (Index)        0.343190
Gleichheit vor dem Gesetz und individuelle Freiheiten (Index)  0.645330
Zugang zur Justiz                0.649881
Rechtsstaatlichkeit(Index)        0.690315
öffentliche Korruption            -0.689218
politische Korruption            -0.718109
Korruption der Exekutive         -0.667066
Fertilitätsrate                  -0.532793
Lebenserwartung                  0.471214
politische Polarisierung         -0.564798
politische Gewalt                -0.789834
Versammlungsfreiheit            0.460383
Massenmobilisierung             -0.362440
Autokratische Bewegungen        -0.468618
Demokratische Bewegungen        -0.411852
Beteiligung an staatlich organisierten Gruppen    -0.382840
Beteiligung an unabhängigen nicht-politischen Gruppen  0.271101
Freiheit von Forschung und Lehre  0.395799
Name: politische Stabilität, dtype: float64
```

```
In [140... # Barplot horizontal
correlation1.sort_values().plot(kind='barh', figsize=(8, 6), color='skyblue')

plt.title('Korrelation mit politischer Stabilität')
plt.xlabel('Korrelationskoeffizient')
plt.ylabel('Variablen')
plt.axvline(0, color='gray', linestyle='--') # Linie bei 0
plt.tight_layout()
plt.show()
```



- Diese Grafik zeigt, welche Variable die politische Stabilität am besten erklärt. Der stärkste Faktor scheint die politische Gewalt zu sein. Darauf folgen die Variablen der politischen Korruption und die Variablen zur institutionellen Qualität (Rechtsstaat, liberale Demokratie, Gleichheit vor dem Gesetz, Zugang zur Justiz)
- Ferner lässt sich erkennen, dass das Cluster funktioniert. Es zeigt eine starke Trennung zwischen den Gruppen, auch in Bezug auf die politische Stabilität.

pca Data -- generell

```
In [141... # Dfs zusammenführen, indem die Spalte politische Stabilität ergänzt wird
merged = pd.concat([data_pca, Data[["politische Stabilität"]]], axis=1)
```


```
In [142... # Korrelationen
correlation2 = merged.corr()[["politische Stabilität"]].drop("politische Stabilität")
correlation2
```

```
Out[142]: PC1    0.709008
PC2   -0.373419
PC3   -0.015217
PC4    0.123451
PC5   -0.194707
PC6   -0.045321
PC7    0.101802
Name: politische Stabilität, dtype: float64
```

In [143...

```
# Barplot horizontal
correlation2.sort_values().plot(kind='barh', figsize=(8, 6), color='skyblue')

plt.title('Korrelation mit politischer Stabilität')
plt.xlabel('Korrelationskoeffizient')
plt.ylabel('Variable')
plt.axvline(0, color='gray', linestyle='--') # Linie bei 0
plt.tight_layout()
plt.show()
```



- PC1 ist der zentrale Treiber politischer Stabilität (stark positive Korrelation) --> starke Institutionen, wenig Korruption, starke Rechtsstaatlichkeit = hohe Stabilität.
- PC2 scheint auch relevant zu sein (mittlere negative Korrelation) --> soziale Unruhe oder Protestpotenzial = geringere Stabilität.
- PC3–PC7 tragen wenig bis gar nichts zur Erklärung der politischen Stabilität bei.
- Das Clustering funktioniert gut (aufgrund von PC1): Es trennt die Länder in zwei Gruppen, die sich deutlich in ihrer politischen Stabilität unterscheiden. Negativer Zusammenhang: Weil Cluster 0 stabile Länder enthält und mit 0 codiert ist. Cluster 1 ist mit 1 codiert.

Zusammenfassende Schlussfolgerung des Vergleichs mit der Korrelation zur Zielvariable

- Das Cluster ohne PCA hat den Vorteil, dass die Variablen direkt mit der Zielvariable korrelieren können. Wodurch ermittelt werden kann welche Variablen vermutlich den stärksten Einfluss auf die Zielvariable haben.
- Schaut man sich jedoch die Korrelation der Cluster zur Zielvariable an, dann stellt man fest, dass das Cluster mit PCA minimal stärker mit der politischen Stabilität korreliert (0.635446 vs. 0.636220), was bedeutet, dass dieses Clustering auch minimal besser funktioniert hat.

Nr 3)

Zusammenfassung der erzielten Ergebnisse

Zentrale Ergebnisse der Analyse:

- Hauptkomponentenanalyse (PCA) reduzierte die Vielzahl an Variablen auf sieben Hauptkomponenten, wobei PC1 mit 56 % der Varianz der mit Abstand wichtigste Faktor war. Insgesamt war der Unterschied zwischen der Nutzung von PCA und der Nichtnutzung jedoch nicht allzu groß.
- PC1 steht für starke Institutionen, Rechtsstaatlichkeit und geringe Korruption, was gleichzeitig die Kernelemente politischer Stabilität sind.
- Ferner identifizierte die Clusteranalyse zwei Gruppen von Ländern (Sowohl Kmeans als auch HAC. DBSCAN hat nicht wirklich funktioniert):

Cluster 0: Länder mit stabilen, demokratischen Strukturen, geringer Korruption, aber mäßiger Mobilisierung.

Cluster 1: Länder mit schwächeren Institutionen, aber stärkerer zivilgesellschaftlicher Aktivität, höherer politischer Gewalt und höherer Korruption. Diese Länder waren zu Zeitpunkt der Datenerhebung mutmaßlich politisch instabil oder gefährdet.

- Weiterhin zeigte PC2 (Demokratische Bewegungen & Meinungsfreiheit) eine negative Korrelation mit der politischen Stabilität --> Hinweis auf mögliche Protest- oder Unruherisiken.
- Die Politische Gewalt war die stärkste Einzelvariable zur Erklärung von Instabilität, gefolgt von Korruption und institutioneller Qualität (liberale Demokratie, Gleichheit vor dem Gesetz, faire und freie Wahlen etc).
- Mit HAC hätte man eventuell noch kleiner Cluster entdecken können. Die Clusterqualität wäre jedoch sehr schlecht gewesen. Die dominierenden Variablen wären jedoch ähnlich geblieben.

Vergleich mit dem ursprünglichen Plan (Pitch)

Die Analyse erfüllte die Hauptziele des ursprünglichen Projekts recht gut:

- Es wurden politische Risikomuster erkannt,
- Es wurden Schlüsselfaktoren der Instabilität identifiziert
- Und es wurde ein Clusterstruktur gefunden welches stark mit der Zielgröße politischer Stabilität korreliert.

Gleichzeitig zeigte sich, dass nicht alle zivilgesellschaftlichen Aktivitäten ein Risiko darstellen, sondern in stabilen Demokratien auch Ausdruck gesunder Partizipation sein können – ein wichtiger, differenzierender Erkenntnisgewinn gegenüber der Ausgangshypothese.

Nr. 4)

Das Clustering generierte wertvolle Erkenntnisse darüber, welche Länder ein erhöhtes Risiko politischer Instabilität aufweisen.

- Das Clustering teilt Länder zuverlässig in zwei Gruppen:

Stabil: starke Institutionen, geringe Korruption, hohe Rechtsstaatlichkeit.

Gefährdet/Instabil: schwache Institutionen, politische Gewalt, erhöhte zivilgesellschaftliche Spannung, erhöhte Korruption.

- Die Hauptfaktoren sind politisch beeinflussbar und konnten identifiziert werden (Korruption, Gewalt, demokratische Rechte) --> konkret beeinflussbar
- Um zu Erkennen ob ein Land auf eine Instabilität zusteuert, müssen die genannten Faktoren beobachtet werden, um Trends erkennen zu können.

Nr 5)

- Die Clusteranalysen reduzieren politische Realität auf zwei Gruppen, obwohl es oft viele Zwischentöne gibt (z. B. hybride Regime, fragile Demokratien). Außerdem ist jedes Land sehr individuell. Die Ergebnisse lassen sich nicht immer verallgemeinern.
- Die Analyse basiert auf dem V-Dem-Datensatz, der von Expertenurteilen und Modellen abhängig ist. Deshalb spielt die Voreingenommenheit der Experten eine Rolle.
- Die Daten und Analysen sind oft historisch, während politische Entwicklungen schnell verlaufen.
- es konnten keine spezifischen Veränderungen Variablen erkannt werden, die einen Trend einläuten.

Nr 6)

- Ich hätte mithilfe der Dendogramme beim Clustern mit HAC kleinere Gruppen von Ländern mit spezifischen Merkmalen identifizieren können.
- Szenarienanalyse: Was passiert bei Veränderung einzelner Variablen? Dadurch könnte beobachtet werden wie und warum sich ein Land von dem einen Cluster in das andere verschiebt.
- Zeitreihenbasierte Stabilitätsprognose mit Recurrent Neural Networks: Die politische Stabilität ist dynamisch. Solch ein Modell könnte helfen, zeitliche Muster in der Entwicklung einzelner Länder zu erkennen und zukünftige Instabilität vorherzusagen.
- Integration externer Krisenindikatoren (z. B. Arbeitslosigkeit, Konflikte): Wirtschaftliche oder geopolitische Schocks sind oft Trigger für Instabilität.

Nr 7)

Die angewandte Methodik liefert insgesamt solide und nachvollziehbare Ergebnisse, weist jedoch auch einige Einschränkungen auf, die bei der Interpretation berücksichtigt werden müssen. Die Hauptkomponentenanalyse (PCA) ermöglichte eine Reduktion der Datenkomplexität und identifizierte zentrale politische Dimensionen wie institutionelle Qualität, Korruption oder gesellschaftliche Mobilisierung. Dennoch basiert PCA auf linearen Zusammenhängen und kann dadurch komplexe, nicht-lineare Muster in politischen Entwicklungen nur begrenzt erfassen.

Die Clusteranalyse vereinfacht politische Realitäten, die häufig nicht binär sind. Die klare Trennung in zwei Ländergruppen bietet zwar analytische Klarheit, kann aber Übergangstaaten oder hybride Regime nur unzureichend abbilden. Hinzu kommt, dass Ausreißer oder extreme Werte die Clusterbildung stark beeinflussen können.

Ein weiterer Schwachpunkt liegt in der Zielgrößenbeziehung: Die verwendete Zielvariable „politische Stabilität“ wurde nicht näher definiert (zumindest nicht im Codebook des V-Dem Institutes), wodurch unklar bleibt, wie unabhängig sie von den erklärenden Variablen ist.

Man hätte wahrscheinlich die zeitliche Entwicklung besser aufgreifen können. Ebenso war mein Vorgehen bei der Bearbeitung der Aufgaben unübersichtlich und ich musste mir oft erst klar werden, was ich eigentlich machen soll und was sinnvoll ist. Ich hätte mir für jede Aufgabe einen Ablaufplan schreiben können. Dadurch hätte ich die Methoden vielleicht intensiver ausführen können.

Wahrscheinlich hätte man die Parameter, vorallem beim DBSCAN irgendwie auch besser einstellen können. Ich hätte auch mehr Methoden verwenden können, die die Clusterstruktur besser beschreiben. Auch methoden aus der Vorlesung.

Nr 8)

Ich würde den Pitch jetzt gerne nochmal erstellen. Ich hätte inhaltlich einfach viel mehr gewusst. Auch hätte ich genauer beschreiben können, welche Clusteranalysen sinnhaft gewesen wären und welche nicht. So wie ich den Pitch erstellt habe, habe ich nur eine grobe Zielrichtung genannt. Daher habe ich meine Ziele recht gut erreichen können. Auch wenn ich keine länderspezifischen Trends entdecken konnte. Dies liegt allerdings auch daran, dass ich mich an die Aufgabenstellung gehalten habe. Dieses selbstgesteckte Ziel war jedoch nicht so wirklich mit der Aufgabenstellung des Clusters zu vereinbaren. Zumindest nicht für meine Kenntnisse. Die Tatsache, dass ich gemeinsame Muster und Faktoren mit starkem Einfluss identifizieren konnte, zeigt jedoch, dass die Ziele ansonsten mit der Aufgabenstellung vereinbar waren und somit auch realistisch.